

# 第三章 非线性规划


## 第四节 无约束优化问题的解法

- ✓ 最速下降法
  - *Newton*法
  - 拟*Newton*法
  - 共轭梯度法

## 最速下降法迭代原理:

$$\min_{X \in R^n} f(X) \quad \lambda_0 \text{——最优步长}$$

$$\lambda_1 \text{——最优步长}$$



$$X^0, \quad p^0 = -\nabla f(X^0), \quad \min_{\lambda \geq 0} f(X^0 + \lambda p^0) = f(X^0 + \lambda_0 p^0), \quad X^1 = X^0 + \lambda_0 p^0$$

$$X^1, \quad p^1 = -\nabla f(X^1), \quad \min_{\lambda \geq 0} f(X^1 + \lambda p^1) = f(X^1 + \lambda_1 p^1), \quad X^2 = X^1 + \lambda_1 p^1$$

$$X^k, \quad p^k = -\nabla f(X^k), \quad \min_{\lambda \geq 0} f(X^k + \lambda p^k) = f(X^k + \lambda_k p^k), \quad X^{k+1} = X^k + \lambda_k p^k$$

得到一个点列:  $X^0, X^1, \dots, X^{(k)}, \dots$ ,


可以证明:  $f(X^{(k)})$  严格  $\downarrow$ ,  $\therefore X^{(k)} \xrightarrow[k \rightarrow \infty]{} X^*$  (Th 3-10),  
线性收敛 (Th 3-11)

结论: 最速下降法的任何两个相邻搜索方向正交:  $p^{(k+1)T} p^{(k)} = 0$

## 最速下降法迭代原理:

$$\min_{X \in R^n} f(X) = x_1^4 + x_2^2 + 2$$

$$\nabla f(X) = (4x_1^3, 2x_2)^T$$



$$X^0, p^0 = -\nabla f(X^0), \min_{\lambda \geq 0} f(X^0 + \lambda p^0) = f(X^0 + \lambda_0 p^0), X^1 = X^0 + \lambda_0 p^0$$

$$X^0 = (1, 1)^T, p^0 = -\nabla f(X^0) = -(4, 2)^T$$

$$X^0 + \lambda p^0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \lambda \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 - 4\lambda \\ 1 - 2\lambda \end{pmatrix}$$

$$f(X^0 + \lambda p^0) = (1 - 4\lambda)^4 + (1 - 2\lambda)^2 + 2 = F(\lambda)$$

$$\min_{\lambda \geq 0} f(X^0 + \lambda p^0) = F(\lambda)$$

$\lambda$	$F(\lambda)$
0	4
0.5	3
1	84


一维搜索找极小点  $\lambda_0$  : 1) 确定  $[0, 1]$ , 精度 0.1

2) 用 0.618 法得到  $\lambda_0 = 0.34375$

## 最速下降法迭代原理:

$$\min_{X \in R^n} f(X) = x_1^4 + x_2^2 + 2$$

$$\nabla f(X) = (4x_1^3, 2x_2)^T$$



$$X^0, p^0 = -\nabla f(X^0), \min_{\lambda \geq 0} f(X^0 + \lambda p^0) = f(X^0 + \lambda_0 p^0), X^1 = X^0 + \lambda_0 p^0$$

$$X^0 = (1, 1)^T, p^0 = -\nabla f(X^0) = -(4, 2)^T$$

$$X^0 + \lambda p^0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \lambda \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 - 4\lambda \\ 1 - 2\lambda \end{pmatrix}$$

$$f(X^0 + \lambda p^0) = (1 - 4\lambda)^4 + (1 - 2\lambda)^2 + 2 = F(\lambda)$$

$$\min_{\lambda \geq 0} f(X^0 + \lambda p^0) = F(\lambda) \quad \lambda_0 = 0.34375$$

$$X^1 = (1, 1)^T - 0.34375(4, 2)^T = (-0.375, 0.3125)^T$$

$$f(X_1) = 2.11743 < f(X_0) = 4$$

# 第三章 非线性规划

## 第四节 无约束优化问题的解法

✓ 最速下降法

➡ *Newton*法

■ 拟*Newton*法

■ 共轭梯度法

## 二. *Newton*法

$$(NP) \min_{X \in R^n} f(X)$$

➡ *Newton*法的迭代原理

- *Newton*法的收敛结论
- *Newton*法注释
- *Newton*法的优缺点

## 1. *Newton*法的迭代原理

设  $f(X)$  在上  $R^n$  具有连续的二阶偏导数,  
即  $G(X) = \nabla^2 f(X)$  连续, 且  $G(X^*)$  正定。

在  $X^*$  的邻域内,  $G(X)$  也正定。

求解  $\min_{X \in R^n} f(X)$  的局部最优解  $X^*$

$$\nabla^2 f(X) = \nabla(\nabla f(X)) = \nabla \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix} = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

## 1. *Newton*法的迭代原理 $X^{(k)} \longrightarrow X^{(k+1)}$

在 $X^{(k)}$ 处用 $f(X)$ 的正定二次函数来近似 $f(X)$ :

一元函数泰勒公式:

$$f(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2} f''(x_k)(x - x_k)^2 + o(x - x_k)^2$$

$$f(x) \cong f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2} f''(x_k)(x - x_k)^2 = \varphi(x)$$

$$f(X) \cong f(X^{(k)}) + g(X^{(k)})^T (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T G(X^{(k)}) (X - X^{(k)}) = \varphi(X)$$

$$g(X^{(k)}) = \nabla f(X^{(k)}) \quad G(X^{(k)}) = \nabla^2 f(X^{(k)})$$



1. *Newton*法的迭代  $f(X) = \frac{1}{2} X^T Q X + b^T X$  用  $\varphi(X)$  近似  $f(X)$

在  $X^{(k)}$  处用正定二次函数来近似  $f(X)$  用  $\varphi(X)$  的极小点  $X^{k+1}$

$$f(x) \cong f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2} f''(x_k)(x - x_k)^2$$

近似  $f(X)$  的极小点  $X^*$

$$f(X) \cong f(X^{(k)}) + g(X^{(k)})^T (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T G(X^{(k)}) (X - X^{(k)}) = \varphi(X)$$

$\because G(X^*)$  正定, 且  $G(X)$  连续  $\therefore$  在  $X^*$  附近,  $G(X^{(k)})$  也正定.

$\therefore \varphi(X)$  为正定二次函数. 求  $\varphi(X)$  的极小点:

$$\nabla \varphi(X) = G(X^{(k)})(X - X^{(k)}) + g(X^{(k)}) = \mathbf{0} \longrightarrow$$

$$G(X^{(k)})(X - X^{(k)}) = -g(X^{(k)}) \longrightarrow X - X^{(k)} = -G(X^{(k)})^{-1} g(X^{(k)})$$

$$X = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

*Newton*迭代公式

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

线性规划3-4

## 二. *Newton*法

$$(NP) \min_{X \in R^n} f(X)$$

- ✓ *Newton*法的迭代原理
- ➡ *Newton*法的收敛结论
- *Newton*法注释
- *Newton*法的优缺点

## 2. *Newton*法的收敛结论

$$g(X^{(k)}) = \nabla f(X^{(k)})$$

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

$$G(X^{(k)}) = \nabla^2 f(X^{(k)})$$

*Newton*法产生的点列:  $X^{(0)}, X^{(1)}, X^{(2)}, \dots, X^{(k)}, \dots$

$$X^{(0)} \quad X^{(1)} = X^{(0)} - G(X^{(0)})^{-1} g(X^{(0)})$$

$$X^{(2)} = X^{(1)} - G(X^{(1)})^{-1} g(X^{(1)})$$

$$X^{(3)} = X^{(2)} - G(X^{(2)})^{-1} g(X^{(2)})$$

**收敛结论:**

当 $X^{(0)}$ 充分靠近 $X^*$ 时,  $X^{(k)} \xrightarrow[k \rightarrow \infty]{\text{二阶收敛}} X^*$

因此, *Newton*法往往与最速下降法结合使用, 前期使用最速下降法, 后期使用*Newton*法.

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

例3-10 用Newton法求  $f(X) = x_1^2 + 4x_2^2$  的极小点,

$$X^{(0)} = (1, 1)^T, \varepsilon = 10^{-4} \quad X^* = (0, 0)^T$$

解:

$$X^{(1)} = X^{(0)} - G(X^{(0)})^{-1} g(X^{(0)})$$

$$g(X) = \nabla f(X) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix} \quad G(X) = \nabla^2 f(X) = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$$

$$g(X^{(0)}) = \nabla f(X^{(0)}) = \begin{pmatrix} 2 \\ 8 \end{pmatrix} \quad G(X^{(0)}) = \nabla^2 f(X^{(0)}) = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$$

$$X^{(1)} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}^{-1} \begin{pmatrix} 2 \\ 8 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 1/2 & 0 \\ 0 & 1/8 \end{pmatrix} \begin{pmatrix} 2 \\ 8 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} = X^*$$

## 二. *Newton*法

$$(NP) \min_{X \in R^n} f(X)$$

- ✓ *Newton*法的迭代原理
- ✓ *Newton*法的收敛结论
- ➔ *Newton*法注释
- *Newton*法的优缺点

### 3. Newton法注释

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

1<sup>0</sup> 由于Newton迭代公式中没有使用一维  $X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$

$$\text{即 } X^{(k+1)} = X^{(k)} + p^{(k)}, \quad p^{(k)} = -G(X^{(k)})^{-1} g(X^{(k)})$$

即  $\lambda_k = 1, \therefore$  不能保证  $\{f(X^{(k)})\}$  严格  $\downarrow$

$\therefore$  不能保证当  $X^{(0)}$  远离极小点  $X^*$  时算法收敛。


**复习：** 要想保证  $\{f(X^{(k)})\}$  严格  $\downarrow$ ，需要保证两条：

1)  $p^{(k)}$  是  $f(X)$  在  $X^{(k)}$  处的下降方向, 即  $\nabla f(X^{(k)})^T p^{(k)} < 0$

2)  $\min_{\lambda \geq 0} f(X^k + \lambda p^k) = f(X^k + \lambda_k p^k), \quad X^{k+1} = X^k + \lambda_k p^k \quad f(X^{k+1}) < f(X^k)$

$p^{(k)} = -G(X^{(k)})^{-1} g(X^{(k)})$  是  $f(X)$  在  $X^{(k)}$  处的下降方向：

$$\nabla f(X^{(k)})^T p^{(k)} = -g(X^{(k)})^T G(X^{(k)})^{-1} g(X^{(k)}) < 0$$

$\therefore G(X^*)$  正定, 且  $G(X)$  连续  $\therefore$  在  $X^*$  附近,  $G(X^{(k)})$  也正定. 

### 3. *Newton*法注释

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

1<sup>0</sup> 由于*Newton*迭代公式中没有使用一维搜索  $X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$

$$\text{即 } X^{(k+1)} = X^{(k)} + p^{(k)}, \quad p^{(k)} = -G(X^{(k)})^{-1} g(X^{(k)})$$

即  $\lambda_k = 1, \therefore$  不能保证  $\{f(X^{(k)})\}$  严格  $\downarrow$

$\therefore$  不能保证当  $X^{(0)}$  远离极小点  $X^*$  时算法收敛。

2<sup>0</sup> 为了保证在  $X^{(0)}$  远离极小点的地方算法的收敛性,

取  $p^{(k)} = -G(X^{(k)})^{-1} g(X^{(k)})$  为搜索方向,

作一维搜索:  $\min_{\lambda \geq 0} f(X^{(k)} + \lambda p^{(k)}) = f(X^{(k)} + \lambda_k p^{(k)}),$

$$X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$$

这样得到的算法称为阻尼*Newton*法.(P158)

### 3. *Newton*法注释

**3<sup>0</sup>** *Newton*法的搜索方向:  $p^{(k)} = -G(X^{(k)})^{-1}g(X^{(k)})$ ,

最速下降法的搜索方向:  $p^{(k)} = -g(X^{(k)})$

*Newton*法的搜索方向与最速下降法相比较, 不仅利用了梯度的信息, 还利用了*Hesse*矩阵的信息, 从而提高了收敛速度(二阶收敛)。

**4<sup>0</sup>** 对于正定二次目标函数, 使用*Newton*法只需迭代一次就可求出它的极小点。所以*Newton*法具有二次终止性。



$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

例3-10 用Newton法求  $f(X) = x_1^2 + 4x_2^2$  的极小点,

$$X^{(0)} = (1, 1)^T, \varepsilon = 10^{-4} \quad X^* = (0, 0)^T$$

解:

$$X^{(1)} = X^{(0)} - G(X^{(0)})^{-1} g(X^{(0)})$$

$$g(X) = \nabla f(X) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix} \quad G(X) = \nabla^2 f(X) = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$$

$$g(X^{(0)}) = \nabla f(X^{(0)}) = \begin{pmatrix} 2 \\ 8 \end{pmatrix} \quad G(X^{(0)}) = \nabla^2 f(X^{(0)}) = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$$

$$X^{(1)} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}^{-1} \begin{pmatrix} 2 \\ 8 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 1/2 & 0 \\ 0 & 1/8 \end{pmatrix} \begin{pmatrix} 2 \\ 8 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} = X^*$$

## 1. *Newton*法的迭代原理 $X^{(k)} \longrightarrow X^{(k+1)}$

在 $X^{(k)}$ 处用正定二次函数来近似 $f(X)$ :

$$f(x) \cong f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2} f''(x_k)(x - x_k)^2 = \varphi(x)$$

$$\underline{f(X) \cong f(X^{(k)}) + g(X^{(k)})^T (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T G(X^{(k)}) (X - X^{(k)}) = \varphi(X)}$$

$\because G(X^*)$ 正定, 且 $G(X)$ 连续  $\therefore$  在 $X^*$ 附近,  $G(X^{(k)})$ 也正定.

$\therefore \varphi(X)$ 为正定二次函数 . 求 $\varphi(X)$ 的极小点 :

$$\nabla \varphi(X) = G(X^{(k)})(X - X^{(k)}) + g(X^{(k)}) = \mathbf{0} \longrightarrow$$

$$G(X^{(k)})(X - X^{(k)}) = -g(X^{(k)}) \longrightarrow X - X^{(k)} = -G(X^{(k)})^{-1} g(X^{(k)})$$

$$X = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

***Newton*迭代公式**

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

## 二. *Newton*法

$$(NP) \min_{X \in R^n} f(X)$$

- ✓ *Newton*法的迭代原理
- ✓ *Newton*法的收敛结论
- ✓ *Newton*法注释
- ➡ *Newton*法的优缺点

## 4. *Newton*法的优缺点

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

优点:  $X^{(k)} \xrightarrow[k \rightarrow \infty]{\text{二阶收敛}} X^*$

*Newton*法最突出的优点是收敛速度快.

缺点: 每次迭代都要计算目标函数的*Hesse*阵的逆阵,当维数 $n$ 较大时,计算量迅速增加,这就抵消了*Newton*法的优点.

## 二. *Newton*法

$$(NP) \min_{X \in R^n} f(X)$$

- ✓ *Newton*法的迭代原理
- ✓ *Newton*法的收敛结论
- ✓ *Newton*法注释
- ✓ *Newton*法的优缺点

# 第三章 非线性规划

## 第四节 无约束优化问题的解法

✓ 最速下降法

✓ *Newton*法

➡ 拟*Newton*法

■ 共轭梯度法

### 三. 拟Newton法

*Newton*迭代公式:  $X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1}g(X^{(k)})$

*Newton*法搜索方向:  $p^{(k)} = -G(X^{(k)})^{-1}g(X^{(k)})$


拟*Newton*法搜索方向:  $p^{(k)} = -H^{(k)}g(X^{(k)})$

$H^{(k)}$ 是  $G(X^{(k)})^{-1}$  的近似

拟*Newton*法是一大类算法的总称,其中使用最多的是**DFP**方法和**BFGS**方法.

### 三. 拟Newton法----*DFP*法 (Davidon-Fletcher-Powell)

$$(NP) \min_{X \in R^n} f(X)$$

 *DFP*法的搜索方向

- *DFP*法的迭代步骤
- *DFP*法举例
- *DFP*法的性质
- *DFP*法的收敛结论



$$f(X) \cong f(X^{(k)}) + g(X^{(k)})^T (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T G(X^{(k)}) (X - X^{(k)}) = \varphi(X)$$

**问题：** 如何确定  $H^{(k)}$ ?

$$H^{(k)} \rightarrow H^{(k+1)} ?$$

$H^{(k)}$  是  $G(X^{(k)})^{-1}$  的近似  
 $H^{(k+1)}$  是  $G(X^{(k+1)})^{-1}$  的近似

$$f(X) \cong f(X^{(k+1)}) + g(X^{(k+1)})^T (X - X^{(k+1)}) + \frac{1}{2} (X - X^{(k+1)})^T G(X^{(k+1)}) (X - X^{(k+1)})$$

$$\nabla f(X) \cong g(X^{(k+1)}) + G(X^{(k+1)}) (X - X^{(k+1)})$$

$$\nabla f(X^{(k)}) \cong g(X^{(k+1)}) + G(X^{(k+1)}) (X^{(k)} - X^{(k+1)})$$

$$g^{(k)} \cong g^{(k+1)} + G^{(k+1)} (X^{(k)} - X^{(k+1)})$$

$$g^{(k+1)} - g^{(k)} \cong G^{(k+1)} (X^{(k+1)} - X^{(k)}) \quad (G^{(k+1)} \text{ 正定})$$

$$G^{(k+1)^{-1}} \underbrace{(g^{(k+1)} - g^{(k)})}_{Y^{(k)}} \cong \underbrace{X^{(k+1)} - X^{(k)}}_{S^{(k)}}$$


$$G^{(k+1)^{-1}} Y^{(k)} \approx S^{(k)} \quad \mathbf{H^{(k+1)} Y^{(k)} = S^{(k)}} \quad (3-35) \text{ 称为拟Newton方程}$$

$\because G(X^*)$  正定, 且  $G(X)$  连续  
 $\therefore$  在  $X^*$  附近,  $G(X^{(k+1)})$  也正定.

## 1. DFP法的搜索方向

**问题：** 如何确定  $H^{(k)}$ ?

$$H^{(k)} \rightarrow H^{(k+1)} ?$$



**1°**  $H^{(k+1)}$  满足拟Newton方程

**2°** 为使搜索方向  $p^{(k)} = -H^{(k)} g^{(k)}$  是下降方向，要求  $H^{(k)}$  对称正定。

**结论：** 当  $\nabla f(X^{(k)})^T p^{(k)} < 0$  时， $p^{(k)}$  是  $f(X)$  在  $X^{(k)}$  处的下降方向。

**证明：** 当  $H^{(k)}$  对称正定时， $g^{(k)T} p^{(k)} = -g^{(k)T} H^{(k)} g^{(k)} < 0$ ，  
所以  $p^{(k)}$  是  $f(X)$  在  $X^{(k)}$  处的下降方向。

### 三. 拟Newton法

#### 复习

#### 迭代原理:

Newton迭代公式:

Newton法搜索方向:

拟Newton法搜索方向:

$$X^{(k+1)} = X^{(k)} - G(X^{(k)})^{-1} g(X^{(k)})$$

$$p^{(k)} = -G(X^{(k)})^{-1} g(X^{(k)})$$

$$p^{(k)} = -H^{(k)} g(X^{(k)})$$

$H^{(k)}$  是  $G(X^{(k)})^{-1}$  的近似

#### 要求:

$$H^{(k)} Y^{(k-1)} = S^{(k-1)}$$

1<sup>0</sup>  $H^{(k)}$  满足拟Newton方程; (保证算法收敛快 – 超线性收敛)

2<sup>0</sup>  $H^{(k)}$  对称正定;  $g^{(k)T} p^{(k)} = -g^{(k)T} H^{(k)} g^{(k)} < 0$ ,

(保证搜索方向  $p^{(k)}$  是下降方向  $\rightarrow f(X^{(k)}) \downarrow \rightarrow X^{(k)} \rightarrow X^*$ )

**结论:** 当  $\nabla f(X^{(k)})^T p^{(k)} < 0$  时,  $p^{(k)}$  是  $f(X)$  在  $X^{(k)}$  处的下降方向

## 1. DFP法的搜索方向

**问题：** 如何确定  $H^{(k)}$ ?

$$H^{(k)} \rightarrow H^{(k+1)} ?$$

$$p^{(k)} = -H^{(k)} g^{(k)}$$

$H^{(k)}$  是  $G(X^{(k)})^{-1}$  的近似

$H^{(k+1)}$  是  $G(X^{(k+1)})^{-1}$  的近似

$$H^{(k+1)} Y^{(k)} = S^{(k)}$$

**1<sup>0</sup>**  $H^{(k+1)}$  满足拟Newton方程

**2<sup>0</sup>** 为使搜索方向  $p^{(k)} = -H^{(k)} g^{(k)}$  是下降方向，要求  $H^{(k)}$  对称正定。

**3<sup>0</sup>** 要求  $H^{(k+1)} - H^{(k)} = \Delta H^{(k)}$  越简单越好，即秩越小越好。

DFP方法如何确定  $\Delta H^{(k)}$ :

$$H^{(k+1)} - H^{(k)} = \Delta H^{(k)} \underset{\text{令}}{=} \alpha_k U^{(k)} U^{(k)T} + \beta_k V^{(k)} V^{(k)T}$$

$$H^{(k+1)} = H^{(k)} + \alpha_k U^{(k)} U^{(k)T} + \beta_k V^{(k)} V^{(k)T}$$

其中  $U^{(k)}, V^{(k)}$  是  $n$  维待定列向量， $\alpha_k, \beta_k$  是待定常数。

**可以证明：**  $\Delta H^{(k)}$  是一个秩2对称矩阵。

$$H^{(k+1)}Y^{(k)} = S^{(k)}$$
$$\mathbf{Y}^{(k)} = \mathbf{g}^{(k+1)} - \mathbf{g}^{(k)}$$

$$H^{(k+1)} = H^{(k)} + \alpha_k U^{(k)} U^{(k)T} + \beta_k V^{(k)} V^{(k)T}$$

$$S^{(k)} = X^{(k+1)} - X^{(k)}$$


$$\begin{aligned} H^{(k+1)}Y^{(k)} &= H^{(k)}Y^{(k)} + \alpha_k \underline{U^{(k)}U^{(k)T}Y^{(k)}} + \beta_k \underline{V^{(k)}V^{(k)T}Y^{(k)}} \\ &= H^{(k)}Y^{(k)} + \underbrace{\alpha_k (U^{(k)T}Y^{(k)})}_{=1} U^{(k)} + \underbrace{\beta_k (V^{(k)T}Y^{(k)})}_{=-1} V^{(k)} \end{aligned}$$

$$\alpha_k = \frac{\mathbf{1}}{U^{(k)T} \mathbf{Y}^{(k)}} = \frac{\mathbf{1}}{S^{(k)T} \mathbf{Y}^{(k)}} \quad \beta_k = -\frac{\mathbf{1}}{V^{(k)T} \mathbf{Y}^{(k)}} = -\frac{\mathbf{1}}{\mathbf{Y}^{(k)T} \mathbf{H}^{(k)} \mathbf{Y}^{(k)}}$$

$$\mathbf{H}^{(k+1)} = \mathbf{H}^{(k)} - \frac{\mathbf{H}^{(k)} \mathbf{Y}^{(k)} \mathbf{Y}^{(k)T} \mathbf{H}^{(k)}}{\mathbf{Y}^{(k)T} \mathbf{H}^{(k)} \mathbf{Y}^{(k)}} + \frac{\mathbf{S}^{(k)} \mathbf{S}^{(k)T}}{\mathbf{S}^{(k)T} \mathbf{Y}^{(k)}} \quad (3-38)$$

**DFP公式**

# 1. DFP法的搜索方向



$$p^{(k)} = -H^{(k)} g^{(k)}$$

$$H^{(k+1)} = H^{(k)} - \frac{H^{(k)} Y^{(k)} Y^{(k)T} H^{(k)}}{Y^{(k)T} H^{(k)} Y^{(k)}} + \frac{S^{(k)} S^{(k)T}}{S^{(k)T} Y^{(k)}} \quad (3-38)$$

**DFP公式**


$$X^{(0)}, H^{(0)} = E \quad p^{(0)} = -H^{(0)} g^{(0)} = -g^{(0)} \quad \text{一维搜索得 } X^{(1)}$$

$$X^{(1)}, \quad p^{(1)} = -H^{(1)} g^{(1)} \quad \text{一维搜索得 } X^{(2)}$$

$$S^{(0)} = X^{(1)} - X^{(0)} \quad Y^{(0)} = g^{(1)} - g^{(0)}$$

$$H^{(1)} = H^{(0)} - \frac{H^{(0)} Y^{(0)} Y^{(0)T} H^{(0)}}{Y^{(0)T} H^{(0)} Y^{(0)}} + \frac{S^{(0)} S^{(0)T}}{S^{(0)T} Y^{(0)}}$$

# 1. DFP法的搜索方向



$$p^{(k)} = -H^{(k)} g^{(k)}$$

$$H^{(k+1)} = H^{(k)} - \frac{H^{(k)} Y^{(k)} Y^{(k)T} H^{(k)}}{Y^{(k)T} H^{(k)} Y^{(k)}} + \frac{S^{(k)} S^{(k)T}}{S^{(k)T} Y^{(k)}} \quad (3-38)$$

**DFP公式**

$$X^{(0)}, H^{(0)} = E \quad p^{(0)} = -H^{(0)} g^{(0)} = -g^{(0)} \quad \text{一维搜索得 } X^{(1)}$$

$$X^{(1)}, \quad p^{(1)} = -H^{(1)} g^{(1)} \quad \text{一维搜索得 } X^{(2)}$$

$$X^{(2)}, \quad p^{(2)} = -H^{(2)} g^{(2)} \quad \text{一维搜索得 } X^{(3)}$$

$$S^{(1)} = X^{(2)} - X^{(1)} \quad Y^{(1)} = g^{(2)} - g^{(1)}$$

$$H^{(2)} = H^{(1)} - \frac{H^{(1)} Y^{(1)} Y^{(1)T} H^{(1)}}{Y^{(1)T} H^{(1)} Y^{(1)}} + \frac{S^{(1)} S^{(1)T}}{S^{(1)T} Y^{(1)}}$$

### 三. 拟Newton法 ---- DFP法

$$(NP) \min_{X \in R^n} f(X)$$

✓ DFP法的搜索方向

➡ DFP法的迭代步骤

- DFP法举例
- DFP法的性质
- DFP法的收敛结论



## 2. DFP法的迭代步骤:

1<sup>0</sup> 给定初始点  $X^{(1)}$ , 容许误差  $\varepsilon > 0$ ;

2<sup>0</sup> 检验  $\|g(X^{(1)})\| < \varepsilon$ ? 若满足, 则迭代终止, 取  $X^* = X^{(1)}$ , 否则转 3<sup>0</sup>

3<sup>0</sup> 取  $H^{(1)} = E$ , 令  $k = 1$       4<sup>0</sup> 令  $p^{(k)} = -H^{(k)} g^{(k)}$

5<sup>0</sup> 一维搜索:  $\min_{\lambda \geq 0} f(X^{(k)} + \lambda p^{(k)}) = f(X^{(k)} + \lambda_k p^{(k)})$

6<sup>0</sup> 令  $X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$

7<sup>0</sup> 检验  $\|g(X^{(k+1)})\| < \varepsilon$ ? 若满足, 则迭代终止, 取  $X^* = X^{(k+1)}$ ,

否则若  $k = n$ , 令  $X^{(1)} := X^{(k+1)}$ , 转 3<sup>0</sup>

若  $k < n$ , 令  $Y^{(k)} = g^{(k+1)} - g^{(k)}$ ,  $S^{(k)} = X^{(k+1)} - X^{(k)}$ ,

计算  $H^{(k+1)} = H^{(k)} - \frac{H^{(k)} Y^{(k)} Y^{(k)T} H^{(k)}}{Y^{(k)T} H^{(k)} Y^{(k)}} + \frac{S^{(k)} S^{(k)T}}{S^{(k)T} Y^{(k)}}$ , 转 8<sup>0</sup>

8<sup>0</sup> 令  $k := k + 1$ , 转 4<sup>0</sup>

**$n = 3$**

$$X^{(1)}, \quad H^{(1)} = E \quad k := 1 \quad p^{(1)} = -H^{(1)}g^{(1)} = -g^{(1)} \quad X^{(2)} = X^{(1)} + \lambda_1 p^{(1)}$$

$$X^{(2)}, \quad k=1 < n=3 \quad p^{(2)} = -H^{(2)}g^{(2)} \quad X^{(3)} = X^{(2)} + \lambda_2 p^{(2)}$$

$$S^{(1)} = X^{(2)} - X^{(1)}$$

$$Y^{(1)} = g^{(2)} - g^{(1)}$$

$$H^{(2)} = H^{(1)} - \frac{H^{(1)}Y^{(1)}Y^{(1)T}H^{(1)}}{Y^{(1)T}H^{(1)}Y^{(1)}} + \frac{S^{(1)}S^{(1)T}}{S^{(1)T}Y^{(1)}}$$

**$k := k + 1 = 2$  转4<sup>0</sup>**

$$X^{(3)}, \quad k=2 < n=3 \quad p^{(3)} = -H^{(3)}g^{(3)} \quad X^{(4)} = X^{(3)} + \lambda_3 p^{(3)}$$

$$S^{(2)} = X^{(3)} - X^{(2)}$$

$$Y^{(2)} = g^{(3)} - g^{(2)}$$

$$H^{(3)} = H^{(2)} - \frac{H^{(2)}Y^{(2)}Y^{(2)T}H^{(2)}}{Y^{(2)T}H^{(2)}Y^{(2)}} + \frac{S^{(2)}S^{(2)T}}{S^{(2)T}Y^{(2)}}$$

**$k := k + 1 = 3$  转4<sup>0</sup>**

$$X^{(4)}, \quad k=3=n=3 \quad X^{(1)} := X^{(4)} \text{ 转3}^0 \quad \mathbf{k} := 1 \quad p^{(1)} = -H^{(1)}g^{(1)} = -g^{(1)}$$

**2<sup>0</sup>**  $\|g(X^{(1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(1)}$ , 否则转 **3<sup>0</sup>** **3<sup>0</sup>**  $H^{(1)} = E, k = 1$  **4<sup>0</sup>**  $p^{(k)} = -H^{(k)}g^{(k)}$

**5<sup>0</sup>**  $\min_{\lambda \geq 0} f(X^{(k)} + \lambda p^{(k)}) = f(X^{(k)} + \lambda_k p^{(k)})$  **6<sup>0</sup>**  $X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$

**7<sup>0</sup>**  $\|g(X^{(k+1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(k+1)}$ , 否则若  **$k = n$** , 令  $X^{(1)} := X^{(k+1)}$ , 转 **3<sup>0</sup>**

若  **$k < n$** , 令  $Y^{(k)} = g^{(k+1)} - g^{(k)}$ ,  $S^{(k)} = X^{(k+1)} - X^{(k)}$ ,  $H^{(k+1)} = H^{(k)} - \frac{H^{(k)}Y^{(k)}Y^{(k)T}H^{(k)}}{Y^{(k)T}H^{(k)}Y^{(k)}} + \frac{S^{(k)}S^{(k)T}}{S^{(k)T}Y^{(k)}}$ , 转 **8<sup>0</sup>**

**8<sup>0</sup>** 令  $k := k + 1$ , 转 **4<sup>0</sup>**

线性规划3-4

## 2. DFP法的迭代步骤:

3<sup>0</sup> 取  $H^{(1)} = E$ , 令  $k = 1$       4<sup>0</sup> 令  $p^{(k)} = -H^{(k)} g^{(k)}$

5<sup>0</sup> 一维搜索  $\min_{\lambda \geq 0} f(X^{(k)} + \lambda p^{(k)}) = f(X^{(k)} + \lambda_k p^{(k)})$      $n = 3$

6<sup>0</sup> 令  $X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$

7<sup>0</sup> 检验  $\|g(X^{(k+1)})\| < \varepsilon$ ?

否则若  $k = n$ , 令  $X^{(1)} := X^{(k+1)}$ , 转 3<sup>0</sup>

若  $k < n$ ,  $H^{(k)} \xrightarrow{\text{DFP公式}} H^{(k+1)}$ , 8<sup>0</sup>

8<sup>0</sup> 令  $k := k + 1$ , 转 4<sup>0</sup>

$$X^{(1)}, p^{(1)} = -H^{(1)} g^{(1)} = -g^{(1)}$$

$$X^{(2)}, p^{(2)} = -H^{(2)} g^{(2)}$$

$$X^{(3)}, p^{(3)} = -H^{(3)} g^{(3)}$$

$$X^{(4)}, p^{(4)} = -H^{(4)} g^{(4)} = -g^{(4)}$$

$$X^{(5)}, p^{(5)} = -H^{(5)} g^{(5)}$$

$$X^{(6)}, p^{(6)} = -H^{(6)} g^{(6)}$$

每  $n$  次迭代中的第一步取负梯度方向为其搜索方向, 这种做法简称为 “ **$n$ 步重新开始**”. 这是为了减少舍入误差的影响(舍入误差可能导致某个  $H^{(k)}$  不可逆或不正定)

### 三. 拟Newton法 ---- DFP法

$$(NP) \min_{X \in R^n} f(X)$$

✓ DFP法的搜索方向

✓ DFP法的迭代步骤

➡ DFP法举例

- DFP法的性质

- DFP法的收敛结论

### 3. DFP法举例

例3-13 用DFP方法求解  $\min f(X) = x_1^2 + 4x_2^2 = \frac{1}{2} X^T Q X$ ,  $n = 2$   
取  $X^{(1)} = (1, 1)^T$  为初始点,  $\varepsilon = 0.01$

解:  $Q = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$   $g(X) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix}$   $g^{(1)} = \begin{pmatrix} 2 \\ 8 \end{pmatrix}$   $\|g^{(1)}\| = \sqrt{68} < \varepsilon$

$2^0 \|g(X^{(1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(1)}$ , 否则转  $3^0$   $3^0 H^{(1)} = E, k=1$   $4^0 p^{(k)} = -H^{(k)} g^{(k)}$   $X^{(1)} = (1, 1)^T$   
 $5^0 \min_{\lambda \geq 0} f(X^{(k)} + \lambda p^{(k)}) = f(X^{(k)} + \lambda_k p^{(k)})$   $6^0 X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$   
 $7^0 \|g(X^{(k+1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(k+1)}$ , 否则若  $k = n$ , 令  $X^{(1)} := X^{(k+1)}$ , 转  $3^0$   
 若  $k < n$ , 令  $Y^{(k)} = g^{(k+1)} - g^{(k)}, S^{(k)} = X^{(k+1)} - X^{(k)}, H^{(k+1)} = H^{(k)} - \frac{H^{(k)} Y^{(k)} Y^{(k)T} H^{(k)}}{Y^{(k)T} H^{(k)} Y^{(k)}} + \frac{S^{(k)} S^{(k)T}}{S^{(k)T} Y^{(k)}}$ , 转  $8^0$   
 $8^0$  令  $k := k + 1$ , 转  $4^0$

解:  $Q = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$   $g(X) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix}$   $g^{(1)} = \begin{pmatrix} 2 \\ 8 \end{pmatrix}$   $\|g^{(1)}\| = \sqrt{68} < \varepsilon$   
 $k=1$   $H^{(1)} = E, p^{(1)} = -H^{(1)} g^{(1)} = -g^{(1)} = -\begin{pmatrix} 2 \\ 8 \end{pmatrix}$

所以DFP方法与最速下降法具有相同的第一个迭代点。

$X^{(2)} = \begin{pmatrix} 0.73846 \\ -0.04616 \end{pmatrix}$   $g^{(2)} = \begin{pmatrix} 1.47692 \\ -0.36923 \end{pmatrix}$   $\|g^{(2)}\| = 1.52237 < \varepsilon$

$\because k=1 < n=2 \therefore$  计算  $H^{(2)}$ :  $S^{(1)} = X^{(2)} - X^{(1)} = \begin{pmatrix} -0.26154 \\ -1.04616 \end{pmatrix}$

$S^{(1)} S^{(1)T} = \begin{pmatrix} 0.06840 & 0.27361 \\ 0.27361 & 1.09445 \end{pmatrix}$   $Y^{(1)} = g^{(2)} - g^{(1)} = \begin{pmatrix} -0.52308 \\ -8.36923 \end{pmatrix}$

$S^{(1)T} Y^{(1)} = 8.89236$

$2^0 \|g(X^{(1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(1)}$ , 否则转  $3^0$   $3^0 H^{(1)} = E, k=1$   $4^0 p^{(k)} = -H^{(k)} g^{(k)}$   $X^{(1)} = (1, 1)^T$   
 $5^0 \min_{\lambda \geq 0} f(X^{(k)} + \lambda p^{(k)}) = f(X^{(k)} + \lambda_k p^{(k)})$   $6^0 X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$   
 $7^0 \|g(X^{(k+1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(k+1)}$ , 否则若  $k = n$ , 令  $X^{(1)} := X^{(k+1)}$ , 转  $3^0$   
 若  $k < n$ , 令  $Y^{(k)} = g^{(k+1)} - g^{(k)}$ ,  $S^{(k)} = X^{(k+1)} - X^{(k)}$ ,  $H^{(k+1)} = H^{(k)} - \frac{H^{(k)} Y^{(k)} Y^{(k)T} H^{(k)}}{Y^{(k)T} H^{(k)} Y^{(k)}} + \frac{S^{(k)} S^{(k)T}}{S^{(k)T} Y^{(k)}}$ , 转  $8^0$   
 $8^0$  令  $k := k + 1$ , 转  $4^0$

解:  $Q = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$   $g(X) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix}$   $g^{(1)} = \begin{pmatrix} 2 \\ 8 \end{pmatrix}$   $\|g^{(1)}\| = \sqrt{68} < \varepsilon$

$k = 1$   $\because k = 1 < n = 2 \therefore$  计算  $H^{(2)}$ :

$$S^{(1)} S^{(1)T} = \begin{pmatrix} 0.06840 & 0.27361 \\ 0.27361 & 1.09445 \end{pmatrix} \quad S^{(1)T} Y^{(1)} = 8.89236 \quad Y^{(1)} = g^{(2)} - g^{(1)} = \begin{pmatrix} -0.52308 \\ -8.36923 \end{pmatrix}$$

$$H^{(1)} Y^{(1)} Y^{(1)T} H^{(1)} = Y^{(1)} Y^{(1)T} = \begin{pmatrix} 0.27361 & 4.37778 \\ 4.37778 & 70.4401 \end{pmatrix}$$

$$Y^{(1)T} H^{(1)} Y^{(1)} = Y^{(1)T} Y^{(1)} = 70.31762$$

$$H^{(2)} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} - \frac{1}{70.31} \begin{pmatrix} 0.27 & 4.37 \\ 4.37 & 70.4 \end{pmatrix} + \frac{1}{8.89} \begin{pmatrix} 0.06 & 0.27 \\ 0.27 & 1.09 \end{pmatrix} = \begin{pmatrix} 1.00 & -0.03 \\ -0.03 & 0.12 \end{pmatrix}$$

**2<sup>0</sup>**  $\|g(X^{(1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(1)}$ , 否则转 **3<sup>0</sup>** **3<sup>0</sup>**  $H^{(1)} = E, k = 1$  **4<sup>0</sup>**  $p^{(k)} = -H^{(k)}g^{(k)}$   $X^{(1)} = (1, 1)^T$

**5<sup>0</sup>**  $\min_{\lambda \geq 0} f(X^{(k)} + \lambda p^{(k)}) = f(X^{(k)} + \lambda_k p^{(k)})$  **6<sup>0</sup>**  $X^{(k+1)} = X^{(k)} + \lambda_k p^{(k)}$

**7<sup>0</sup>**  $\|g(X^{(k+1)})\| < \varepsilon$ ? 若是,  $X^* = X^{(k+1)}$ , 否则若  $k = n$ , 令  $X^{(1)} := X^{(k+1)}$ , 转 **3<sup>0</sup>**

若  $k < n$ , 令  $Y^{(k)} = g^{(k+1)} - g^{(k)}, S^{(k)} = X^{(k+1)} - X^{(k)}, H^{(k+1)} = H^{(k)} - \frac{H^{(k)}Y^{(k)}Y^{(k)T}H^{(k)}}{Y^{(k)T}H^{(k)}Y^{(k)}} + \frac{S^{(k)}S^{(k)T}}{S^{(k)T}Y^{(k)}}$ , 转 **8<sup>0</sup>**

**8<sup>0</sup>** 令  $k := k + 1$ , 转 **4<sup>0</sup>**

$$\lambda_2 = -\frac{g^{(2)T}p^{(2)}}{p^{(2)T}Qp^{(2)}}$$

解:  $Q = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$   $g(X) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix}$   $g^{(1)} = \begin{pmatrix} 2 \\ 8 \end{pmatrix}$   $\|g^{(1)}\| = \sqrt{68} < \varepsilon$

$k = 2$   $X^{(2)} = \begin{pmatrix} 0.73846 \\ -0.04616 \end{pmatrix}$   $g^{(2)} = \begin{pmatrix} 1.47692 \\ -0.36923 \end{pmatrix}$   $H^{(2)} = \begin{pmatrix} 1.00 & -0.03 \\ -0.03 & 0.12 \end{pmatrix}$

$p^{(2)} = -H^{(2)}g^{(2)} = \begin{pmatrix} -1.49 \\ 0.09 \end{pmatrix}$   $\lambda_2 = -\frac{g^{(2)T}p^{(2)}}{p^{(2)T}Qp^{(2)}} (3-13)P_{155}$

$X^{(3)} = X^{(2)} + \lambda_2 p^{(2)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$   $g^{(3)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$   $\|g^{(3)}\| = 0 < \varepsilon \therefore X^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$



### 3. DFP法举例

$n = 2$

例3-13 用 $DFP$ 方法求解  $\min f(X) = x_1^2 + 4x_2^2 = \frac{1}{2} X^T Q X$ ,  
取  $X^{(1)} = (1,1)^T$  为初始点,  $\varepsilon = 0.01$

注释:

$f(X)$  是二维正定二次函数,两次迭代就求出了极小点,这不是偶然。是因为 $DFP$ 方法具有二次终止性。对于 $n$ 维正定二次函数,最多经过 $n$ 次迭代就可以求到极小点。

### 三. 拟Newton法 ---- DFP法

$$(NP) \min_{X \in R^n} f(X)$$

✓ DFP法的搜索方向

✓ DFP法的迭代步骤

✓ DFP法举例

➡ DFP法的性质

■ DFP法的收敛结论

## 4. DFP法的性质

$$p^{(k)} = -H^{(k)} g^{(k)}$$

$$H^{(k+1)} = H^{(k)} - \frac{H^{(k)} Y^{(k)} Y^{(k)T} H^{(k)}}{Y^{(k)T} H^{(k)} Y^{(k)}} + \frac{S^{(k)} S^{(k)T}}{S^{(k)T} Y^{(k)}}$$

**性质1：**若  $H^{(k)}$  对称正定，则  $H^{(k+1)}$  也对称正定。

**性质2：**对于正定二次函数  $f(X) = \frac{1}{2} X^T Q X + b^T X + c$   
当  $H^{(1)} = E$  时，则

**(1)** DFP方法产生的搜索方向  $p^{(1)}, p^{(2)}, \dots, p^{(m)}$  是互相  $Q$  共轭的。

因此DFP方法是一种共轭方向法,具有二次终止性。  
对于 $n$ 维正定二次函数，最多经过 $n$ 次迭代就可以求到极小点。

## 4. DFP法的性质

$$p^{(k)} = -H^{(k)} g^{(k)}$$

$$H^{(k+1)} = H^{(k)} - \frac{H^{(k)} Y^{(k)} Y^{(k)T} H^{(k)}}{Y^{(k)T} H^{(k)} Y^{(k)}} + \frac{S^{(k)} S^{(k)T}}{S^{(k)T} Y^{(k)}}$$

**性质1：** 若  $H^{(k)}$  对称正定，则  $H^{(k+1)}$  也对称正定。

**性质2：** 对于正定二次函数  $f(X) = \frac{1}{2} X^T Q X + b^T X + c$   
当  $H^{(1)} = E$  时，则

**(1)** DFP方法产生的搜索方向  $p^{(1)}, p^{(2)}, \dots, p^{(m)}$  是互相  $Q$  共轭的。

**(2)** 若经过  $n$  次迭代才求到极小点，则有： $H^{(n+1)} = Q^{-1}$ .  
( $H^{(k)}$  是  $G^{-1}(X^{(k)}) = Q^{-1}$  的近似)

### 三. 拟Newton法 ---- DFP法

$$(NP) \min_{X \in R^n} f(X)$$

✓ DFP法的搜索方向

✓ DFP法的迭代步骤

✓ DFP法举例

✓ DFP法的性质

➡ DFP法的收敛结论

## 5. DFP法的收敛结论

**结论1:** 由于 $DFP$ 方法是一种共轭方向法,因此是一种收敛算法. 即  $X^{(k)} \xrightarrow[k \rightarrow \infty]{} X^*$

**结论2:** 由于  $p^{(k)} = -H^{(k)} g^{(k)}$ ,  $H^{(k)}$  是  $G^{-1}(X^{(k)})$  的近似,

$$\therefore X^{(k)} \xrightarrow[k \rightarrow \infty]{\text{超线性}} X^*$$

**优点:** 计算方便,收敛速度快. 被中小型问题广泛使用。

**缺点:** 由于舍入误差可能导致某个 $H^{(k)}$ 奇异或不正定,这时可以重置  $H^{(k)} = E$

### 三. 拟Newton法 ---- DFP法

$$(NP) \min_{X \in R^n} f(X)$$

- ✓ DFP法的搜索方向
- ✓ DFP法的迭代步骤
- ✓ DFP法举例
- ✓ DFP法的性质
- ✓ DFP法的收敛结论

### 三. 拟Newton法 ---- BFGS方法

拟Newton法中比DFP法更好的算法是BFGS算法。一般认为BFGS算法是目前最有效的算法，不仅对于精确的一维搜索，就是对于满足一定条件的不精确的一维搜索，也具有超线性收敛性。

BFGS算法中  $H^{(k)}$  的迭代公式是：

$$H^{(k+1)} = H^{(k)} + \left[ \left( 1 + \frac{Y^{(k)T} H^{(k)} Y^{(k)}}{S^{(k)T} Y^{(k)}} \right) S^{(k)} S^{(k)T} - S^{(k)} Y^{(k)T} H^{(k)} + H^{(k)} Y^{(k)} S^{(k)T} \right] \frac{1}{S^{(k)T} Y^{(k)}}$$

—————  $P_{176}$

只要在DFP算法中将  $H^{(k)}$  的计算用上式代替就构成了BFGS算法。因为用上式计算， $H^{(k)}$  不易变为奇异或不正定，所以BFGS算法比DFP算法具有更好的数值稳定性。



# 第三章 非线性规划

## 第四节 无约束优化问题的解法

- ✓ 最速下降法
- ✓ *Newton*法
- ✓ 拟*Newton*法
- 共轭梯度法

作业： P245    15(1)    18(1)

作业： P155    15(1)    18(1)