

第三章 非线性规划

第五节 约束优化问题的最优性条件

回顾：无约束优化问题的最优性条件

X^* 是 $\min_{X \in R^n} f(X)$ 的局部最优解 $\longrightarrow \nabla f(X^*) = 0$

$\longleftarrow \nabla f(X^*) = 0, \nabla^2 f(X^*)$ 正定

任务：讨论约束优化问题的一阶必要条件

(NP) $\min f(X)$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

一阶必要条件:

等式约束问题

$$(NP1) \quad \min f(X) \\ s.t. \quad h_j(X) = 0 \quad \mu_j \\ j = 1, 2, \dots, p$$

Lagrange函数: $L(X, \mu) = f(X) + \sum_{j=1}^p \mu_j h_j(X)$

结论:

设 X^* 是(NP1)最优解, 则存在Lagrange乘子 μ^* 使

$$\nabla_X L(X^*, \mu^*) = \nabla f(X^*) + \sum_{j=1}^p \mu_j^* \nabla h_j(X^*) = 0, \quad \mu^* = (\mu_1^*, \mu_2^*, \dots, \mu_p^*)$$

即 X^* 是(NP1)最优解



$$\nabla f(X^*) + \sum_{j=1}^p \mu_j^* \nabla h_j(X^*) = 0$$

一阶必要条件

μ^* 称为 X^* 相应的Lagrange乘子

一阶必要条件： 不等式约束问题

$$(NP2) \quad \min f(X)$$

$$s.t. \quad g_i(X) \geq 0 \quad \mu_i$$

$$i = 1, 2, \dots, m$$

设 X^* 是(NP2)最优解,

起作用约束: $g_i(X^*) = 0$,

起作用约束指标集: $E = \{i \mid g_i(X^*) = 0, i = 1, \dots, m\}$

定理5-1 Kuhn-Tucher条件(K-T条件): 一阶必要条件

设 X^* 是局部极小点,
 $f, g_i, \forall i$ 在 X^* 连续可微,
 $\nabla g_i(X^*), i \in E$ 线性无关,

则存在 $\mu^* = (\mu_1^*, \mu_2^*, \dots, \mu_m^*)$ 满足

$$\begin{cases} \nabla f(X^*) - \sum_{i=1}^m \mu_i^* \nabla g_i(X^*) = 0 \\ \mu_i^* \geq 0, i = 1, 2, \dots, m \\ \mu_i^* g_i(X^*) = 0, i = 1, \dots, m \end{cases}$$

广义Lagrange函数: $L(X, \mu) = f(X) - \sum_{i=1}^m \mu_i g_i(X)$

一阶必要条件: $(NP) \min f(X)$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m & \lambda_i \\ h_j(X) = 0, j = 1, 2, \dots, p & \mu_j \end{cases}$$

定理5-3 Kuhn-Tucher条件(K-T条件):

设 X^* 是局部极小点, $f, g_i, h_j, \forall i, j$ 在 X^* 连续可微,
 $\nabla g_i(X^*), i \in E$ 和 $\nabla h_j(X^*), j = 1, \dots, p$ 线性无关, 则存在

λ_i^*, μ_j^* 满足

$$\begin{cases} \nabla f(X^*) - \sum_{i=1}^m \lambda_i^* \nabla g_i(X^*) - \sum_{j=1}^p \mu_j^* \nabla h_j(X^*) = 0 \\ \lambda_i^* \geq 0, i = 1, 2, \dots, m \\ \lambda_i^* g_i(X^*) = 0, i = 1, \dots, m \quad (\text{互补条件}) \end{cases}$$

注意: 相应于 \geq 约束, 要求 $\lambda_i^* \geq 0, i = 1, \dots, m$

例： 试写出 $\min f(X) = x_1$ 的K-T条件

$$s.t. \begin{cases} g(X) = 16 - (x_1 - 4)^2 - x_2^2 \geq 0 & \lambda \\ h(X) = (x_1 - 3)^2 + (x_2 - 2)^2 - 13 = 0 & \mu \end{cases}$$

解： $\nabla f(X) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, $\nabla g(X) = \begin{pmatrix} -2(x_1 - 4) \\ -2x_2 \end{pmatrix}$, $\nabla h(X) = \begin{pmatrix} 2(x_1 - 3) \\ 2(x_2 - 2) \end{pmatrix}$,

所以，Kuhn-Tucher条件(K-T条件)为

$$\begin{cases} \begin{pmatrix} 1 \\ 0 \end{pmatrix} - \lambda \begin{pmatrix} -2(x_1 - 4) \\ -2x_2 \end{pmatrix} - \mu \begin{pmatrix} 2(x_1 - 3) \\ 2(x_2 - 2) \end{pmatrix} = 0 \\ \lambda[16 - (x_1 - 4)^2 - x_2^2] = 0 \\ \lambda \geq 0 \\ h(X) = (x_1 - 3)^2 + (x_2 - 2)^2 - 13 = 0 \end{cases}$$

可分析出哪些是可能的解点。

$$\begin{cases} \nabla f(X^*) - \sum_{i=1}^m \lambda_i^* \nabla g_i(X^*) - \sum_{j=1}^p \mu_j^* \nabla h_j(X^*) = 0 \\ x_2^* \geq 0 \\ \lambda_i^* \geq 0, i = 1, 2, \dots, m \\ g_i(X^*) = 0, i = 1, \dots, m \end{cases}$$

例： 试写出 $\min f(X) = x_1$ 的K-T条件

$$s.t. \begin{cases} g(X) = 16 - (x_1 - 4)^2 - x_2^2 \geq 0 & \lambda \\ h(X) = (x_1 - 3)^2 + (x_2 - 2)^2 - 13 = 0 & \mu \end{cases}$$

解： Kuhn-Tucher条件(K-T条件)为

$$\begin{cases} \begin{pmatrix} 1 \\ 0 \end{pmatrix} - \lambda \begin{pmatrix} -2(x_1 - 4) \\ -2x_2 \end{pmatrix} - \mu \begin{pmatrix} 2(x_1 - 3) \\ 2(x_2 - 2) \end{pmatrix} = 0 & \star \\ \lambda[16 - (x_1 - 4)^2 - x_2^2] = 0, & \lambda \geq 0 & \star \\ h(X) = (x_1 - 3)^2 + (x_2 - 2)^2 - 13 = 0 & \star \end{cases}$$

$$\Rightarrow \begin{cases} x_1 = 3 + \sqrt{13} \\ x_2 = 2 \\ \mu = \sqrt{13}/26 \\ \lambda = 0 \end{cases} \quad \begin{cases} x_1 = 0 \\ x_2 = 0 \\ \mu = 0 \\ \lambda \neq 0 \rightarrow \lambda = \frac{1}{8} \end{cases} \quad \begin{cases} x_1 = 6.4 \\ x_2 = 3.2 \\ \mu = 1/5 \\ \lambda \neq 0 \rightarrow \lambda = \frac{3}{40} \end{cases}$$

第三章 非线性规划

第六节 罚函数法(SUMT法)

$$(NP) \quad \min f(X)$$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$


- ➡ 外点罚函数法(外点法)
- 内点罚函数法(内点法)
- 混合点罚函数法(混合点法)

第三章 非线性规划

一. 外点罚函数法(外点法)

$$(NP) \quad \min f(X)$$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

 外点法迭代原理

- 外点法迭代步骤
- 外点法举例
- 外点法的优缺点

一. 外点法迭代原理

$$\begin{aligned} (NP) \quad & \min f(X) \\ & s.t. \quad g_i(X) \geq 0 \\ & \quad \quad i = 1, 2, \dots, m \end{aligned}$$



$$\begin{aligned} (NP) \quad & \min f(X) \\ & s.t. \quad \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases} \end{aligned}$$

一. 外点法迭代原理

基本思想:

通过建立罚函数, 将约束极值问题转化
成一系列无约束极值问题去求解.


$$\begin{aligned} (NP) \quad & \min f(X) \\ & s.t. \quad g_i(X) \geq 0 \\ & \quad \quad i = 1, 2, \dots, m \end{aligned}$$

构造罚函数: $\varphi(X, M) = f(X) + \underbrace{M \sum_{i=1}^m [\min(0, g_i(X))]^2}_{\text{罚因子} \times \text{惩罚项}}$

罚函数的特点:

$$\varphi(X, M) = \begin{cases} f(X), & X \in D \text{可行域} \\ f(X) + \text{很大的正数}, & X \notin D \end{cases}$$

(当 M 取值很大时)



$$\min_{X \in R^n} \varphi(X, M)$$

至少 $\exists i_0$ 使 $g_{i_0}(X) < 0$
 \therefore 惩罚项 $\geq M g_{i_0}^2(X)$

一. 外点法迭代原理

$$(NP) \quad \min f(X)$$

$$s.t. \quad g_i(X) \geq 0$$

$$i = 1, 2, \dots, m$$

基本思想:

通过建立罚函数, 将约束极值问题转化成一系列无约束极值问题去求解

构造罚函数: $\varphi(X, M) = f(X) + \underbrace{M \sum_{i=1}^m [\min(0, g_i(X))]^2}_{\text{罚因子} \times \text{惩罚项}}$

罚函数的特点:

$$\varphi(X, M) = \begin{cases} f(X), & X \in D \\ f(X) + \text{很大的正数}, & X \notin D \end{cases}$$

$(NP) \rightarrow$ 求解 $\min_{X \in R^n} \varphi(X, M)$ 设其最优解为 $X^*(M)$, 研究 $X^*(M)$ 与 (NP) 的最优解 X^* 之间的关系

一. 外点法迭代原理


$$(NP) \min f(X)$$

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2 \quad s.t. \quad g_i(X) \geq 0 \quad i = 1, 2, \dots, m$$

设 $\min_{X \in R^n} \varphi(X, M)$ 最优解为 $X^*(M)$

研究 $X^*(M)$ 与 (NP) 的最优解 X^* 之间的

1⁰ 若 $X^*(M) \in D$ (可行域), 则 $X^*(M)$ 是 (NP) 最优解。



证明:

$\because X^*(M)$ 是 $\min_{X \in R^n} \varphi(X, M)$ 的最优解, \therefore 有:

$$\because f(X) \underset{\forall X \in D \cap N}{=} \varphi(X, M) \underset{\forall X \in N}{\geq} \varphi(X^*(M), M) \underset{X^*(M) \in D}{=} f(X^*(M))$$

$\therefore X^*(M)$ 是 (NP) 的最优解。

$$\varphi(X, M) = \begin{cases} f(X), & X \in D \\ f(X) + \text{很大的正数}, & X \notin D \end{cases}$$

一. 外点法迭代原理

$$(NP) \min f(X)$$

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2 \quad s.t. \quad g_i(X) \geq 0 \\ i = 1, 2, \dots, m$$

设 $\min_{X \in R^n} \varphi(X, M)$ 最优解为 $X^*(M)$

研究 $X^*(M)$ 与 (NP) 的最优解 X^* 之间的关系

1⁰ 若 $X^*(M) \in D$ (可行域), 则 $X^*(M)$ 是 (NP) 最优解。

2⁰ 若 $X^*(M) \notin D$, 当 M 很大时, $X^*(M)$ 也会相当靠近 (NP) 可行域 D 的边界, \therefore 是 (NP) 的最优解 X^* 的近似解 (通常约束极值问题的最优解 X^* 在可行域的边界上)

一. 外点法迭代原理

$$(NP) \min f(X)$$

$$\varphi(X, M) = f(X) + M \sum [\min(0, g_i(X))]^2 \quad s.t. \quad g_i(X) \geq 0$$

设 $\min_{X \in R^n} \varphi(X, M)$ 的最优解为 $X^*(M)$ $i = 1, 2, \dots, m$

2⁰ 若 $X^*(M) \notin D$, 当 M 很大时, $X^*(M)$ 也会相当靠近

(NP) 可行域 D 的边界, \therefore 是 (NP) 的最优解 X^* 的近似解

证明: $\because X^*(M) \notin D$, \therefore 至少存在 i_0 使 $g_{i_0}(X^*(M)) < 0$

又 $\because X^*(M)$ 是 $\min_{X \in R^n} \varphi(X, M)$ 的最优解,

$\therefore \varphi(X^*(M), M) = f(X^*(M)) + M \sum [\min(0, g_i(X^*(M)))]^2$ 是局部极小值

\therefore 当 M 很大时, $\sum [\min(0, g_i(X^*(M)))]^2$ 会相当小。

$$\text{即 } g_{i_0}^2(X^*(M)) \leq \sum [\min(0, g_i(X^*(M)))]^2 < \varepsilon^2 \longrightarrow |g_{i_0}(X^*(M))| < \varepsilon$$

$$\longrightarrow -\varepsilon < g_{i_0}(X^*(M)) < 0$$

一. 外点法迭代原理

$$(NP) \min f(X)$$

$$\varphi(X, M) = f(X) + M \sum [\min(0, g_i(X))]^2 \quad s.t. \quad g_i(X) \geq 0$$

$$i = 1, 2, \dots, m$$


设 $\min_{X \in R^n} \varphi(X, M)$ 的最优解为 $X^*(M)$

2⁰ 若 $X^*(M) \notin D$, 当 M 很大时, $X^*(M)$ 也会相当靠近

(NP) 可行域 D 的边界, \therefore 是 (NP) 的最优解 X^* 的近似解

证明: $\because X^*(M) \notin D, \therefore$ 至少存在 i_0 使 $g_{i_0}(X^*(M)) < 0$

当 M 很大时, 有 $-\varepsilon < g_{i_0}(X^*(M)) < 0$



M 越大, ε 越小, $X^*(M)$ 越靠近 D 的边界, 即越靠近 X^* 。 \therefore 增大罚因子 M 的作用是将 $X^*(M)$ 拉向 D 的边界 (即 X^*)。

一. 外点法迭代原理

$$(NP) \min f(X)$$

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2 \quad s.t. \quad g_i(X) \geq 0 \\ i = 1, 2, \dots, m$$

设 $\min_{X \in R^n} \varphi(X, M)$ 最优解为 $X^*(M)$

研究 $X^*(M)$ 与 (NP) 的最优解 X^* 之间的关系

1⁰ 若 $X^*(M) \in D$ (可行域), 则 $X^*(M)$ 是 (NP) 最优解。

2⁰ 若 $X^*(M) \notin D$, 当 M 很大时, $X^*(M)$ 也会相当靠近 (NP) 可行域 D 的边界, \therefore 是 (NP) 的最优解 X^* 的近似解 (通常约束极值问题的最优解 X^* 在可行域的边界上)

问题: 如何取 M , 使得 $X^*(M)$ 是所需要的近似解?

一. 外点法迭代原理

$$(NP) \min f(X)$$

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2 \quad s.t. \quad g_i(X) \geq 0$$
$$i = 1, 2, \dots, m$$

通过迭代逐渐增大罚因子 M :

任意给定初始点 $X^{(0)}$, 初始罚因子 $M_1(=1)>0$

求解 $\min_{X \in R^n} \varphi(X, M_1)$, 若 $X^{(1)}(M_1) \in D$, 则是 (NP) 的最优解. 否则 $M_2=10M_1$

求解 $\min_{X \in R^n} \varphi(X, M_2)$, 若 $X^{(2)}(M_2) \in D$, 则是 (NP) 的最优解. 否则 $M_3=10M_2$

\vdots

\vdots

\vdots

求解 $\min_{X \in R^n} \varphi(X, M_k)$, 若 $X^{(k)}(M_k) \in D$, 则是 (NP) 的最优解. 否则 $M_{k+1}=10M_k$

收敛结论: $X^{(k)}(M_k) \xrightarrow{M_k \rightarrow \infty} X^*$ — (NP) 的最优解

通过建立罚函数, 将约束极值问题转
化成一系列无约束极值问题去求解.

第三章 非线性规划

一. 外点罚函数法(外点法)

$$(NP) \quad \min f(X)$$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

✓ 外点法迭代原理

➡ 外点法迭代步骤

■ 外点法举例

■ 外点法的优缺点

二. 外点法迭代步骤

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2$$

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0$$

$$i = 1, 2, \dots, m$$

1⁰ 给定 $X^{(0)}$, $M_1 (=1) > 0$, $\varepsilon > 0$, $k := 1$

2⁰ 求 $\min_{X \in R^n} \varphi(X, M_k)$ 的最优解 $X^{(k)}(M_k)$


(用数值迭代的方法求解)

3⁰ 若 $g_i(X^{(k)}(M_k)) > -\varepsilon$, $i = 1, 2, \dots, m$,

则迭代终止, $X^* = X^{(k)}(M_k)$

否则取 $M_{k+1} = C M_k$, 其中 $C = 5 \sim 10$

令 $k := k+1$ 转 2⁰



第三章 非线性规划

一. 外点罚函数法(外点法)

$$(NP) \quad \min f(X)$$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

✓ 外点法迭代原理

✓ 外点法迭代步骤

➡ 外点法举例

■ 外点法的优缺点


三. 外点法举例

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2$$

例3-18 $\min f(X) = x_1 + x_2 \quad s.t. \begin{cases} -x_1^2 + x_2 \geq 0 \rightarrow g_1(X) \geq 0 \\ x_1 \geq 0 \rightarrow g_2(X) \geq 0 \end{cases}$

解: $\varphi(X, M_k) = x_1 + x_2 + M_k \{ [\min(0, -x_1^2 + x_2)]^2 + [\min(0, x_1)]^2 \}$
 $= x_1 + x_2 + M_k [(-x_1^2 + x_2)^2 + x_1^2] \quad \because \text{外点法, } X \notin D$

$$\therefore \begin{cases} -x_1^2 + x_2 < 0 \\ x_1 < 0 \end{cases}$$



三. 外点法举例

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2$$


例3-18 $\min f(X) = x_1 + x_2 \quad s.t. \begin{cases} -x_1^2 + x_2 \geq 0 \\ x_1 \geq 0 \end{cases}$

解: $\varphi(X, M_k) = x_1 + x_2 + M_k \{ [\min(0, -x_1^2 + x_2)]^2 + [\min(0, x_1)]^2 \}$
 $= x_1 + x_2 + M_k [(-x_1^2 + x_2)^2 + x_1^2]$

求解 $\min_{X \in R^n} \varphi(X, M_k)$ (用解析法) $\Rightarrow \nabla \varphi(X, M_k) = 0$

$$\begin{cases} \frac{\partial \varphi}{\partial x_1} = 1 + 2M_k(-x_1^2 + x_2)(-2x_1) + 2M_k x_1 = 0 \\ \frac{\partial \varphi}{\partial x_2} = 1 + 2M_k(-x_1^2 + x_2) = 0 \end{cases}$$

解得: $X^{(k)}(M_k) = \begin{pmatrix} -\frac{1}{2(M_k + 1)} \\ \frac{1}{4(M_k + 1)^2} - \frac{1}{2M_k} \end{pmatrix}$



三. 外点法举例


$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2$$

例3-18 $\min f(X) = x_1 + x_2 \quad s.t. \begin{cases} -x_1^2 + x_2 \geq 0 \\ x_1 \geq 0 \end{cases}$

解:


$$X^{(k)}(M_k) = \begin{pmatrix} -\frac{1}{2(M_k+1)} \\ \frac{1}{4(M_k+1)^2} - \frac{1}{2M_k} \end{pmatrix} \xrightarrow{M_k \rightarrow \infty} X^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$M_1 = 1$	$X^{(1)}(1)$
$M_2 = 10$	$X^{(2)}(10)$
$M_3 = 100$	$X^{(3)}(100)$
$M_4 = 1000$	$X^{(4)}(1000)$



一. 外点法迭代原理

$$\begin{aligned} (NP) \quad & \min f(X) \\ & s.t. \quad g_i(X) \geq 0 \\ & \quad \quad i = 1, 2, \dots, m \end{aligned}$$



$$\begin{aligned} (NP) \quad & \min f(X) \\ & s.t. \quad \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases} \end{aligned}$$

外点法也适用于一般情况: $(NP) \min f(X)$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

罚函数:

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2 + M \sum_{j=1}^p h_j^2(X)$$

求解 $\min_{X \in R^n} \varphi(X, M_k)$ 设其最优解为 $X^{(k)}(M_k)$

收敛结论: $X^{(k)}(M_k) \xrightarrow{M_k \rightarrow \infty} X^* \text{ --- } (NP) \text{ 的最优解}$
 $\notin D$

等式约束的停机准则:

$$\because X^{(k)}(M_k) \xrightarrow{M_k \rightarrow \infty} X^* \quad \therefore h_j(X^{(k)}(M_k)) \xrightarrow{M_k \rightarrow \infty} h_j(X^*) = \mathbf{0}$$

$$|h_j(X^{(k)}(M_k))| < \varepsilon \quad j = 1, 2, \dots, p$$

因此在迭代算法中需加入 $|h_j(X^{(k)}(M_k))| < \varepsilon, j = 1, 2, \dots, p$

二. 外点法迭代步骤

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0$$

$$h_j(X) = 0$$

$$\varphi(X, M) = f(X) + M \sum_{i=1}^m [\min(0, g_i(X))]^2 + M \sum_{j=1}^p h_j^2(X)$$

1⁰ 给定 $X^{(0)}$, $M_1 (=1) > 0$, $\varepsilon > 0$, $k := 1$

2⁰ 求 $\min_{X \in R^n} \varphi(X, M_k)$ 的最优解 $X^{(k)}(M_k)$ (用数值迭代的方法求解)

3⁰ 若 $g_i(X^{(k)}(M_k)) > -\varepsilon$, $i = 1, 2, \dots, m$, $|h_j(X^{(k)}(M_k))| < \varepsilon$ $j = 1, 2, \dots, p$

则迭代终止, $X^* = X^{(k)}(M_k)$

否则取 $M_{k+1} = C M_k$, 其中 $C = 5 \sim 10$ 令 $k := k+1$ 转 2⁰

第三章 非线性规划

一. 外点罚函数法(外点法)

$$(NP) \quad \min f(X)$$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

✓ 外点法迭代原理

✓ 外点法迭代步骤

✓ 外点法举例

➡ 外点法的优缺点

四. 外点法的优缺点

优点:

1. 方法简单,计算方便.
2. 初始点选择容易,它可以在整个 n 维空间中选取.

缺点:

1. 当 $X^{(k)}(M_k)$ 接近最优解 X^* 时, 即罚因子 M_k 很大时, 罚函数 $\varphi(X, M_k)$ 的性质变坏,这就使得求解 $\min_{X \in R^n} \varphi(X, M_k)$ 非常困难。
2. 外点法的中间结果不是可行解, 不能作为近似最优解。只有迭代到最后才能得到最优解的近似解。

第三章 非线性规划

一. 外点罚函数法(外点法)

$$(NP) \quad \min f(X)$$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

- ✓ 外点法迭代原理
- ✓ 外点法迭代步骤
- ✓ 外点法举例
- ✓ 外点法的优缺点

第三章 非线性规划

第六节 罚函数法(SUMT法)

$$(NP) \quad \min f(X)$$

$$s.t. \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

✓ 外点罚函数法(外点法)

➡ 内点罚函数法(内点法)

■ 混合点罚函数法(混合点法)

第三章 非线性规划

二. 内点罚函数法(内点法)

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0, i = 1, 2, \dots, m$$

 内点法迭代原理

- 内点法迭代步骤
- 内点法举例
- 内点法的优缺点

一. 内点法迭代原理

$$(NP) \min f(X)$$

基本思想:

$$s.t. g_i(X) \geq 0$$

内点法要求迭代过程始终在可行域内进行. 为此, 把初始点取在可行域内, 并在可行域的边界上设置一道“障碍”, 使迭代点靠近可行域的边界时, 障碍函数值迅速增大, 从而使迭代点始终留在可行域的内部.

构造障碍函数: $\varphi(X, r_k) = f(X) + r_k \underbrace{\sum_{i=1}^m \frac{1}{g_i(X)}}_{\text{障碍项}} \quad (r_k > 0)$ 障碍因子

或 $\varphi(X, r_k) = f(X) - r_k \underbrace{\sum_{i=1}^m \ln(g_i(X))}_{\text{障碍项}}$


一. 内点法迭代原理

$$\text{障碍函数: } \varphi(X, r_k) = f(X) + r_k \sum_{i=1}^m \frac{1}{g_i(X)} \quad (NP) \min f(X) \quad s.t. g_i(X) \geq 0$$

$$\text{或 } \varphi(X, r_k) = f(X) - r_k \sum_{i=1}^m \ln(g_i(X))$$

障碍函数的特点:

$$\varphi(X, r_k) = \begin{cases} f(X) + \text{有限的数值}, & X \in D \text{ 的内部} \rightarrow g_i(X) > 0 \\ +\infty & X \text{ 接近 } D \text{ 的边界} \end{cases} \quad i=1,2,\dots,m$$



$$\begin{aligned} & \downarrow \text{(比如: } g_{i_0}(X) = 0) \\ & g_{i_0}(X) \rightarrow 0 (> 0) \end{aligned}$$

$$\text{则 } \frac{1}{g_{i_0}(X)} \rightarrow +\infty \text{ 或 } \ln(g_{i_0}(X)) \rightarrow -\infty$$


一. 内点法迭代原理

障碍函数: $\varphi(X, r_k) = f(X) + r_k \sum \frac{1}{g_i(X)}$

或 $\varphi(X, r_k) = f(X) - r_k \sum \ln(g_i(X))$

障碍函数的特点:

$$\varphi(X, r_k) = \begin{cases} f(X) + \text{有限的数值}, \\ +\infty \end{cases}$$



当 X 接近 D 的边界

(NP) \longrightarrow 求解 $\min_{X \in R^n} \varphi(X, r_k)$ 设其最优解为 $X^{(k)}(r_k) \subset D$ 的内部
通常 **(NP)** 的最优解 X^* 在 D 的边界上, 为使 $X^{(k)}(r_k) \rightarrow X^*$

$$\varphi(X^{(k)}(r_k), r_k) = f(X^{(k)}(r_k)) - r_k \sum \ln(g_i(X^{(k)}(r_k))) \rightarrow f(X^*)$$

$$\text{则 } r_k \sum_{i=1}^m \ln(g_i(X^{(k)})) \xrightarrow{-\infty} 0 \quad \text{或 } r_k \sum_{i=1}^m \frac{1}{g_i(X^{(k)})} \xrightarrow{+\infty} 0 \longrightarrow r_k \rightarrow 0 \text{ 且很快}$$

收敛结论: 当 $r_k \rightarrow 0$ 且很快时, 则 $X^{(k)}(r_k) \rightarrow X^*$

第三章 非线性规划

二. 内点罚函数法(内点法)

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0, i = 1, 2, \dots, m$$

✓ 内点法迭代原理

➡ 内点法迭代步骤

- 内点法举例

- 内点法的优缺点

二. 内点法迭代步骤

$$\begin{aligned} (NP) \min f(X) \\ s.t. \quad g_i(X) \geq 0 \\ i = 1, 2, \dots, m \end{aligned}$$

$$\varphi(X, r_k) = f(X) + r_k \sum_{i=1}^m \frac{1}{g_i(X)}$$

$$\text{或 } \varphi(X, r_k) = f(X) - r_k \sum_{i=1}^m \ln(g_i(X))$$

1⁰ 取 $r_1 > 0 (=1)$, $\varepsilon > 0$, $k := 1$

2⁰ 取 $X^{(0)} \in D$ (P201/P167) 当 $r_k \rightarrow 0$ 且很快时, 则 $X^{(k)}(r_k) \rightarrow X^*$

3⁰ 求 $\min_{X \in R^n} \varphi(X, r_k)$ 的最优解 $X^{(k)}(r_k)$ (用数值迭代的方法)

4⁰ 检验 $X^{(k)}(r_k)$ 是否满足收敛准则,

若满足, 则迭代终止, $X^* = X^{(k)}(r_k)$

否则取 $r_{k+1} = Cr_k$, 其中 $C = 1/5$ 或 $1/10$ 。令 $k := k+1$ 转 3⁰

二. 内点法迭代步骤

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0$$

$$\varphi(X, r_k) = f(X) + r_k \sum_{i=1}^m \frac{1}{g_i(X)}$$

$$\varphi(X^{(k)}(r_k), r_k) = f(X^{(k)}(r_k)) - r_k \sum_{i=1}^m \ln(g_i(X^{(k)}(r_k))) \rightarrow f(X^*)$$

收敛准则:

当 $r_k \rightarrow 0$ 且很快时,

$$\text{即 } r_k \sum_{i=1}^m \ln(g_i(X^{(k)})) \rightarrow 0 \text{ 或 } r_k \sum_{i=1}^m \frac{1}{g_i(X^{(k)})} \rightarrow 0 \text{ 则 } X^{(k)}(r_k) \rightarrow X^*$$

$$1^0 r_k \sum_{i=1}^m \frac{1}{g_i(X^{(k)})} \leq \varepsilon$$

$$2^0 \left| r_k \sum_{i=1}^m \ln(g_i(X^{(k)})) \right| \leq \varepsilon$$

二. 内点法迭代步骤

$$\varphi(X, r_k) = f(X) + r_k \sum_{i=1}^m \frac{1}{g_i(X)}$$

$$\text{或 } \varphi(X, r_k) = f(X) - r_k \sum_{i=1}^m \ln(g_i(X))$$

$$\begin{aligned} (NP) \min f(X) \\ s.t. \quad g_i(X) \geq 0 \\ i = 1, 2, \dots, m \end{aligned}$$

收敛准则:

$$1^0 r_k \sum_{i=1}^m \frac{1}{g_i(X^{(k)})} \leq \varepsilon$$

$$2^0 \left| r_k \sum_{i=1}^m \ln(g_i(X^{(k)})) \right| \leq \varepsilon$$

$$\because X^{(k)}(r_k) \rightarrow X^*$$

$$3^0 \|X^{(k)} - X^{(k-1)}\| \leq \varepsilon \quad \therefore \text{当 } k \text{ 充分大时, } X^{(k)} \text{ 在 } X^* \text{ 的 } \varepsilon \text{ 邻域内。}$$

$$4^0 |f(X^{(k)}) - f(X^{(k-1)})| \leq \varepsilon$$

二. 内点法迭代步骤

$$\varphi(X, r_k) = f(X) + r_k \sum_{i=1}^m \frac{1}{g_i(X)}$$

$$\text{或 } \varphi(X, r_k) = f(X) - r_k \sum_{i=1}^m \ln(g_i(X))$$

1⁰ 取 $r_1 > 0 (=1)$, $\varepsilon > 0$, $k := 1$

2⁰ 取 $X^{(0)} \in D$ (P201/P167)

3⁰ 求 $\min_{X \in R^n} \varphi(X, r_k)$ 的最优解 $X^{(k)}(r_k)$ (用数值迭代的方法)

4⁰ 检验 $X^{(k)}(r_k)$ 是否满足收敛准则:

若满足, 则迭代终止, $X^* = X^{(k)}(r_k)$

否则取 $r_{k+1} = Cr_k$, 其中 $C = 1/5$ 或 $1/10$ 。令 $k := k+1$ 转 3⁰

$$1^0 r_k \sum_{i=1}^m \frac{1}{g_i(X^{(k)})} \leq \varepsilon$$

$$2^0 \left| r_k \sum_{i=1}^m \ln(g_i(X^{(k)})) \right| \leq \varepsilon$$

$$3^0 \|X^{(k)} - X^{(k-1)}\| \leq \varepsilon$$

$$4^0 |f(X^{(k)}) - f(X^{(k-1)})| \leq \varepsilon$$

第三章 非线性规划

二. 内点罚函数法(内点法)

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0, i = 1, 2, \dots, m$$

✓ 内点法迭代原理

✓ 内点法迭代步骤

➡ 内点法举例

■ 内点法的优缺点

三. 内点法举例

$$\varphi(X, r_k) = f(X) - r_k \sum_{i=1}^m \ln(g_i(X))$$

例3-18 $\min f(X) = x_1 + x_2 \quad \begin{cases} -x_1^2 + x_2 \geq 0 \\ x_1 \geq 0 \end{cases}$

解:

$$\varphi(X, r_k) = x_1 + x_2 - r_k \ln(-x_1^2 + x_2) - r_k \ln x_1$$

求解 $\min_{X \in R^n} \varphi(X, r_k)$

(解析法)



$$\nabla \varphi(X, r_k) = 0$$

$$\begin{cases} \frac{\partial \varphi}{\partial x_1} = 1 - \frac{r_k(-2x_1)}{-x_1^2 + x_2} - \frac{r_k}{x_1} = 0 \\ \frac{\partial \varphi}{\partial x_2} = 1 - \frac{r_k}{-x_1^2 + x_2} = 0 \end{cases}$$

$$\text{解得: } X^{(k)}(r_k) = \begin{pmatrix} \frac{1}{4}(-1 + \sqrt{1 + 8r_k}) \\ \frac{3}{2}r_k - \frac{1}{8}(-1 + \sqrt{1 + 8r_k}) \end{pmatrix} \xrightarrow{r_k \rightarrow 0} X^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

三. 内点法举例

$$\varphi(X, r_k) = f(X) - r_k \sum_{i=1}^m \ln(g_i(X))$$

例3-18 $\min f(X) = x_1 + x_2 \quad s.t. \begin{cases} -x_1^2 + x_2 \geq 0 \\ x_1 \geq 0 \end{cases}$

解:


$$X^{(k)}(r_k) = \begin{pmatrix} \frac{1}{4}(-1 + \sqrt{1 + 8r_k}) \\ \frac{3}{2}r_k - \frac{1}{8}(-1 + \sqrt{1 + 8r_k}) \end{pmatrix} \xrightarrow{r_k \rightarrow 0} X^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$r_1 = 1, \quad X^{(1)}(1)$$

$$r_2 = \frac{1}{5}, \quad X^{(2)}(1/5)$$

$$r_3 = \frac{1}{25}, \quad X^{(3)}(1/25)$$

$$r_4 = \frac{1}{125}, \quad X^{(4)}(1/125)$$



第三章 非线性规划

二. 内点罚函数法(内点法)

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0, i = 1, 2, \dots, m$$

✓ 内点法迭代原理

✓ 内点法迭代步骤

✓ 内点法举例

➡ 内点法的优缺点

四. 内点法的优缺点

优点:

由于迭代点总是在可行域内进行,每一个中间结果都是一个可行解,因此,中间停机的结果可作为近似解.

缺点:

1. 选取初始可行点困难;
2. 只能求解不等式约束问题。

第三章 非线性规划

二. 内点罚函数法(内点法)

$$(NP) \min f(X)$$

$$s.t. \ g_i(X) \geq 0, i = 1, 2, \dots, m$$

- ✓ 内点法迭代原理
- ✓ 内点法迭代步骤
- ✓ 内点法举例
- ✓ 内点法的优缺点

第三章 非线性规划

第六节 罚函数法(SUMT法)

$$(NP) \quad \min f(X)$$

$$s.t. \quad \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

✓ 外点罚函数法(外点法)

✓ 内点罚函数法(内点法)

➡ 混合点罚函数法(混合点法)

三. 混合点法

$$(NP) \min f(X)$$

基本思想:

$$s.t. \begin{cases} g_i(X) \geq 0 \\ h_j(X) = 0 \end{cases}$$

内点法只能求解不等式约束问题, 而外点法可以求解等式约束问题. 混合点法是用内点法来处理不等式约束, 用外点法来处理等式约束的一种罚函数法.

构造罚函数:

$$\varphi(X, r_k) = f(X) - r_k \sum_{i=1}^m \ln(g_i(X)) + \frac{1}{\sqrt{r_k}} \sum_{j=1}^p h_j^2(X)$$

在迭代中, 令 $r_k \downarrow$ 且 $r_k \rightarrow 0$

求解 $\min_{X \in R^n} \varphi(X, r_k)$ 的最优解 $X^{(k)}(r_k)$

收敛结论: $X^{(k)}(r_k) \xrightarrow{r_k \rightarrow 0} X^*$

第三章 非线性规划

第六节 罚函数法(SUMT法)

$$(NP) \quad \min f(X)$$

$$s.t. \quad \begin{cases} g_i(X) \geq 0, i = 1, 2, \dots, m \\ h_j(X) = 0, j = 1, 2, \dots, p \end{cases}$$

- ✓ 外点罚函数法(外点法)
- ✓ 内点罚函数法(内点法)
- ✓ 混合点罚函数法(混合点法)

作业： P246 22(2) 23(2)

作业： P203 3(2) 4(2)